

DETAIL MINI PROJECT

Area: Digital Forensics & Incident Response

Mata Kuliah: Komputasi Berbasis Jaringan

Dokumen ini memuat detail teknis untuk topik mini project log clustering pada forensic timeline data dari log2timeline/Plaso, mencakup deskripsi, infrastruktur, langkah pengerjaan, dan skenario uji coba beserta template pengumpulan data.

TOPIK: LOG CLUSTERING

Eksplorasi Metode Representasi, Clustering, dan Visualisasi untuk Forensic Timeline Data dari Log2timeline/Plaso CSV

1. Deskripsi

Forensic timeline analysis merupakan tahap krusial dalam digital forensic investigation, di mana investigator perlu menganalisis ribuan hingga jutaan event dari berbagai sumber (filesystem, registry, event log, browser history, dll.) yang telah digabungkan oleh tool seperti log2timeline/Plaso ke dalam satu super-timeline CSV. Tantangan utama: volume data yang sangat besar membuat analisis manual tidak feasible, dan investigator membutuhkan cara otomatis untuk mengelompokkan event serupa guna menemukan pola, anomali, dan aktivitas mencurigakan.

Mini project ini mengeksplorasi pipeline end-to-end untuk log clustering pada forensic timeline data. Fokus utama adalah membandingkan berbagai metode di tiga tahap kunci:

- **Representasi teks:** TF-IDF, Word2Vec (Word Embedding), Sentence-BERT (Transformer Embedding), dan Doc2Vec — untuk mengubah deskripsi event log menjadi vektor numerik.
- **Algoritma clustering:** K-Means, DBSCAN, HDBSCAN, Agglomerative Clustering, Gaussian Mixture Model (GMM), **atau** berbagai algoritma pada repositori logparser (<https://github.com/logpai/logparser>) — untuk mengelompokkan event berdasarkan kesamaan semantik dan struktural.
- **Metode visualisasi:** t-SNE, UMAP, PCA, dan dendogram — untuk memvisualisasikan dan menginterpretasi hasil cluster.

Dataset menggunakan output CSV dari log2timeline/Plaso yang dijalankan pada forensic disk image publik (misalnya dari NIST CFReDS, Digital Corpora, atau DFRWS challenge) atau dataset dari Zenodo (<https://zenodo.org/records/15493424>). Evaluasi mencakup kualitas cluster (internal metrics), kecepatan komputasi, dan interpretabilitas hasil bagi forensic investigator. Murni offline analysis, dikerjakan di Google Colab atau komputer lokal/laptop.

2. Infrastruktur

- Google Colab (gratis) atau komputer lokal: semua library pre-installed atau pip-installable (scikit-learn, gensim, sentence-transformers, hdbscan, umap-learn, matplotlib, plotly).
- Dataset: Output CSV dari log2timeline/Plaso pada forensic image publik. Alternatif: sample dataset dari Plaso documentation atau pre-generated Plaso CSV dari DFRWS challenges. Ukuran tipikal ~50K–500K baris.
- Preprocessing: Python + pandas untuk parsing Plaso CSV (kolom: datetime, timestamp_desc, source, source_long, message, filename, dll.). Fokus pada kolom 'message' dan 'source' sebagai input clustering.

- Feature extraction: scikit-learn (TF-IDF), gensim (Word2Vec, Doc2Vec), sentence-transformers (SBERT). GPU Colab opsional untuk SBERT.
- Clustering: scikit-learn (K-Means, Agglomerative, GMM), hdbscan library. Evaluasi: silhouette_score, calinski_harabasz_score, davies_bouldin_score.
- Visualisasi: matplotlib, seaborn, plotly (interaktif), scikit-learn (t-SNE, PCA), umap-learn (UMAP), scipy (dendogram).

3. Langkah

Pekan 1: Dataset acquisition + preprocessing pipeline. Download/generate Plaso CSV dari forensic image publik. Bangun pipeline: parsing CSV, text cleaning (remove paths/hex/timestamps dari message), tokenisasi, stopwords removal. Implementasi TF-IDF baseline + K-Means baseline. Validasi pipeline end-to-end.

Pekan 2: Implementasi representasi (Word2Vec, Doc2Vec, SBERT), seluruh algoritma clustering (DBSCAN, HDBSCAN, Agglomerative, GMM), atau algoritma pada repositori logcluster (<https://github.com/logpai/logparser>). Hyperparameter tuning per metode (grid search pada parameter kunci). Bangun evaluation framework (internal metrics).

Pekan 3: Implementasi metode visualisasi (t-SNE, UMAP, PCA, dendogram). Integrasi pipeline end-to-end: representasi → clustering → visualisasi. Comparative analysis antar kombinasi. Interpretability assessment: apakah cluster bermakna secara forensik?

Pekan 4: Full experiment execution (semua kombinasi). Cross-dataset validation (jalankan pipeline pada Plaso CSV dari forensic image berbeda). Report dan dokumentasi.

4. Skenario Uji Coba

4.1 Variabel Tetap

- Dataset primer: Plaso CSV dari satu forensic image publik (misal NIST CFReDS hacking case image atau Digital Corpora M57-Jean atau dari Zenodo), minimum 50.000 event.
- Preprocessing: lowercase, hapus angka hex panjang (>8 karakter), hapus absolute path prefix, stopwords removal (English + custom forensic stopwords), minimum token length = 2.
- Train/test: tidak berlaku (unsupervised), namun reproducibility dijaga via seed {misal 42, 123, 456, 789, 101} pada setiap stochastic algorithm.
- Kolom input: 'message' sebagai teks utama, 'source' sebagai metadata tambahan.
- Environment: Google Colab CPU (kecuali SBERT yang menggunakan GPU jika tersedia).
- Dimensionality reduction untuk clustering input: 50 dimensi (PCA) untuk high-dimensional representations (TF-IDF, SBERT) sebelum masuk ke clustering algorithms yang sensitif terhadap dimensi tinggi.

4.2 Variabel Manipulasi

Variabel	Level
Representasi Teks	TF-IDF (max_features=5000), Word2Vec (dim=100, window=5), Doc2Vec (dim=100), Sentence-BERT (all-MiniLM-L6-v2, dim=384)
Algoritma Clustering	K-Means (k=auto via Elbow/Silhouette), DBSCAN (eps=auto via k-distance), HDBSCAN (min_cluster_size=auto), Agglomerative (Ward linkage), GMM (n_components=auto via BIC), atau algoritma lain dari repositori logparser
Metode Visualisasi	t-SNE (perplexity=30), UMAP (n_neighbors=15), PCA (2D), Dendrogram (Agglomerative only)
Jumlah Cluster (k)	Optimal (auto-determined), k=10, k=20, k=50

Skenario inti: 4 representasi × 5 clustering × 1 k-optimal = 20 kombinasi × 5 seed = 100 run. Visualisasi: 20 kombinasi × 3 metode viz = 60 plots. Ditambah k-sensitivity: 2 representasi terbaik × 3 k-values tambahan × 5 clustering = 30 run. Total estimasi ~6–8 jam compute.

4.3 Variabel Respon

Variabel	Satuan	Pengukuran
Silhouette Score	float [-1, 1]	Rata-rata kohesi intra-cluster vs separasi inter-cluster. Semakin tinggi semakin baik.
Calinski-Harabasz Index	float	Rasio dispersi antar-cluster vs intra-cluster. Semakin tinggi semakin baik.
Davies-Bouldin Index	float	Rata-rata similarity ratio antar cluster. Semakin rendah semakin baik.
Jumlah Cluster Terdeteksi	count	Jumlah cluster yang dihasilkan (terutama untuk DBSCAN/HDBSCAN).
Noise Ratio	%	Persentase event yang tidak ter-assign ke cluster (DBSCAN/HDBSCAN).
Embedding Time	detik	Waktu untuk mengubah seluruh dataset ke representasi vektor.
Clustering Time	detik	Waktu eksekusi algoritma clustering.
Visualization Time	detik	Waktu rendering visualisasi (t-SNE, UMAP, PCA).
Peak Memory	MB	tracemalloc peak selama pipeline.
Forensic Interpretability	ordinal 1-5	Expert rating: apakah cluster bermakna secara forensik (1=tidak bermakna, 5=sangat bermakna). Dinilai secara kualitatif.

4.4 Template Data — Kualitas Clustering

Tabel berikut diisi untuk setiap kombinasi representasi × clustering (k-optimal, rata-rata 5 seed):

Metrik	K-Means	DBSCAN	HDBSCAN	Agglom.	GMM
Silhouette (TF-IDF)	—	—	—	—	—
Silhouette (Word2Vec)	—	—	—	—	—
Silhouette (Doc2Vec)	—	—	—	—	—
Silhouette (SBERT)	—	—	—	—	—
CH Index (TF-IDF)	—	—	—	—	—
CH Index (Word2Vec)	—	—	—	—	—
CH Index (Doc2Vec)	—	—	—	—	—
CH Index (SBERT)	—	—	—	—	—
DB Index (TF-IDF)	—	—	—	—	—
DB Index (Word2Vec)	—	—	—	—	—
DB Index (Doc2Vec)	—	—	—	—	—
DB Index (SBERT)	—	—	—	—	—

4.4b Template Data — Performa Komputasi

Metrik	TF-IDF	Word2Vec	Doc2Vec	SBERT
Embedding Time (s)	—	—	—	—
Peak Memory (MB)	—	—	—	—
Clustering Time (s) — K-Means	—	—	—	—
Clustering Time (s) — DBSCAN	—	—	—	—
Clustering Time (s) — HDBSCAN	—	—	—	—
Clustering Time (s) — Agglom.	—	—	—	—
Clustering Time (s) — GMM	—	—	—	—
Viz Time (s) — t-SNE	—	—	—	—
Viz Time (s) — UMAP	—	—	—	—
Viz Time (s) — PCA	—	—	—	—

4.5 Visualisasi

Visualisasi:

- Scatter plot 2D (t-SNE, UMAP, PCA) dengan warna per cluster — per kombinasi representasi × clustering. Total: 20 kombinasi × 3 metode visualisasi = 60 plots (disajikan sebagai grid).

- Heatmap Silhouette Score: sumbu-x = clustering method, sumbu-y = representasi, warna = Silhouette Score.
- Critical Difference diagram dari Friedman-Nemenyi test.
- Elbow plot dan Silhouette plot untuk menentukan k-optimal per representasi.
- Dendrogram (Agglomerative) per representasi — menunjukkan hierarki cluster.
- Radar/spider chart: perbandingan multi-metrik (Silhouette, CH, DB, Embedding Time, Clustering Time) per representasi.
- Bar chart: distribusi event source per cluster — menunjukkan apakah cluster menangkap forensic-meaningful groups (misal: cluster didominasi browser activity, cluster lain didominasi filesystem changes).
- Timeline visualization: scatter plot datetime (x) vs cluster (y) — menunjukkan temporal pattern per cluster.
- Word cloud per cluster: top-N kata yang mendominasi setiap cluster — untuk interpretability.
- Pareto front: Silhouette Score vs Computation Time — menunjukkan trade-off kualitas vs efisiensi.
- Cross-dataset validation: ulangi pipeline terbaik pada Plaso CSV dari forensic image kedua, bandingkan konsistensi metrik.